

POSTECH DTAT

Tech Challenge — Fase 3

O Mercado Brasileiro de Dados Big Data & Analytics na AWS com a pesquisa State of Data Brasil

Relatório Técnico

Grupo

Efraim Oliveira
Érica Tarsis
Ricardo Moraes
Rodrigo Bernardino
Thiago Galvão

São Paulo · 2026

Sumário

Sumário	2
Índice de Figuras	4
Índice de Tabelas	4
Resumo Executivo	5
Artefatos e Links do Projeto	5
1. Compreensão do Problema	6
1.1 Contexto e motivação	6
1.2 Pergunta norteadora e desdobramentos	6
1.3 Visão geral da metodologia	7
2. Fontes de Dados, Governança e Premissas	7
2.1 Bases utilizadas e volumetria	7
2.2 Divergência de esquemas e harmonização (de-para)	8
2.3 Premissas versionadas	9
2.4 LGPD e conformidade	9
2.5 Análise Exploratória e Qualidade dos Dados	9
2.6 Nota metodológica: abordagem descritiva e escolhas de representação	10
3. Arquitetura da Solução AWS	11
3.1 Visão geral	11
3.2 Camadas e responsabilidades	11
3.3 Segurança	12
3.4 Execução no AWS Academy Lab e evidências	12
4. Pipeline de Dados	12
4.1 Ingestão (Bronze)	12
4.2 Transformação Bronze → Silver	12
4.3 Transformação Silver → Gold	12
4.4 Catalogação e consultas	13
4.5 Métricas de qualidade do pipeline	13
5. O Mercado Brasileiro de Dados (Pergunta 1)	13
5.1 Base de respondentes	13
5.2 Perfis profissionais	14
5.3 Senioridade	15
6. Perfis Valorizados e Remuneração (Pergunta 2)	16
6.1 A escada salarial por senioridade	16
6.2 Prêmio por especialização	16
6.3 Controle por senioridade: o prêmio de cargo é real?	17
7. Diversidade de Gênero (Pergunta 3)	18
7.1 Participação feminina	18
7.2 Gap salarial controlado por senioridade	18
7.3 Liderança	19
7.4 Decompondo o gap: composição de cargo e diferença residual	19
8. Tecnologias com Maior Adoção (Pergunta 4)	20
8.1 Linguagens	20

8.2 Cloud	20
8.3 Ferramentas de BI	21
9. Inteligência Artificial: Adoção e Impacto (Pergunta 5).....	22
9.1 IA generativa como prioridade corporativa	22
9.2 Uso individual de GenAI e Copilots	23
10. Regiões e Modelos de Trabalho (Pergunta 6).....	24
10.1 Geografia do talento	24
10.2 O gap entre modelo praticado e desejado	25
10.3 Termômetro do mercado.....	25
11. Oportunidades e Desafios (Pergunta 7)	25
11.1 O que decide a escolha de um empregador	25
11.2 As dores de quem já gere times de dados.....	26
11.3 Síntese: oportunidades × desafios.....	27
12. Recomendações Estratégicas.....	27
12.1 Contratação	27
12.2 Capacitação.....	27
12.3 Investimento	27
12.4 Priorização e Quick Wins.....	28
13. Riscos, Limitações e Governança	29
13.1 Matriz de riscos do projeto	29
13.2 Limitações metodológicas	29
13.3 Reprodutibilidade	30
13.4 Validação cruzada das interpretações	30
14. Conclusões	31
15. Referências.....	31

Índice de Figuras

Figura 1 – Arquitetura da solução AWS — fluxo Kaggle → S3 (Bronze/Silver/Gold) → Glue → Athena → consumo.....	11
Figura 2 – Respondentes por edição da pesquisa (cinza: contexto histórico; azul: núcleo obrigatório).....	14
Figura 3 – Participação por grupo de cargo entre contribuidores individuais — 2025/26 (top 9).....	14
Figura 4 – Pirâmide de senioridade por edição (Especialista/Staff+ existe apenas em 2025/26).....	16
Figura 5 – Salário mediano estimado por senioridade e edição (ponto médio de faixa — premissa P3).....	16
Figura 6 – Salário mediano estimado por grupo de cargo — 2025/26 (grupos com n ≥ 30).....	17
Figura 7 – Participação feminina entre os profissionais de dados — série 2019 a 2025/26.....	18
Figura 8 – Salário mediano por gênero, controlado por senioridade — 2025/26.....	19
Figura 9 – Adoção de linguagens no trabalho — série 2019 a 2025/26 (multirresposta).....	20
Figura 10 – Adoção de provedores de cloud — série 2019 a 2025/26 (multirresposta).....	21
Figura 11 – Ferramentas de BI utilizadas no dia a dia — 2025/26.....	22
Figura 12 – IA generativa como prioridade da empresa — visão dos gestores, 2023 a 2025/26.....	22
Figura 13 – Uso individual de IA generativa no trabalho — 2023 a 2025/26 (multirresposta).....	23
Figura 14 – Distribuição regional e salário médio estimado por região — 2025/26.....	24
Figura 15 – Modelo de trabalho praticado versus desejado — 2025/26.....	25
Figura 16 – Critérios decisivos na escolha de onde trabalhar — 2025/26 (multirresposta).....	26

Índice de Tabelas

Tabela 1 – Da evidência à decisão (síntese executiva).....	5
Tabela 2 – Matriz de aderência ao enunciado (Tech Challenge Fase 3).....	6
Tabela 3 – Bases da pesquisa State of Data Brasil utilizadas no projeto.....	7
Tabela 4 – Exemplos do de-para de colunas entre edições (mapa completo versionado no repositório).....	8
Tabela 5 – Premissas analíticas versionadas do projeto.....	9
Tabela 6 – Preenchimento das variáveis-chave do núcleo (n = 14.005) e origem estrutural dos nulos.....	10
Tabela 7 – Camadas de dados, conteúdo e tecnologia.....	11
Tabela 8 – Reconciliação Bronze × Silver por edição (asserções do Glue Job 1).....	12
Tabela 9 – Métricas de execução e qualidade do pipeline.....	13
Tabela 10 – Principais grupos de cargo — 2025/26 (contribuidores individuais, top 9).....	14
Tabela 11 – Salário mediano estimado (R\$/mês, ponto médio) por senioridade e edição.....	16
Tabela 12 – Salário mediano por grupo de cargo no nível Sênior — 2025/26 (controle de composição).....	17
Tabela 13 – Mediana salarial estimada por gênero e nível — 2025/26.....	19
Tabela 14 – Prioridade de IA generativa (% dos gestores respondentes).....	23
Tabela 15 – Uso individual de GenAI (% sobre respondentes válidos).....	24
Tabela 16 – Termômetro do mercado por edição.....	25
Tabela 17 – Principais desafios dos gestores de dados — 2025/26.....	26
Tabela 18 – Matriz-síntese de oportunidades e desafios para a instituição financeira.....	27
Tabela 19 – Priorização das recomendações.....	28
Tabela 20 – Riscos, impacto e mitigação.....	29
Tabela 21 – Hipóteses testadas, resultado da verificação e decisão adotada.....	30

Resumo Executivo

Este relatório apresenta a arquitetura, o pipeline de dados e as conclusões analíticas de um projeto de Big Data & Analytics construído sobre a pesquisa *State of Data Brasil* (Data Hackers/Bain, Kaggle), a serviço de uma instituição financeira de grande porte que pretende expandir sua área de Dados, Analytics e Inteligência Artificial. Foram processadas as três últimas edições da pesquisa (2023, 2024 e 2025/26) como núcleo obrigatório e as edições 2019, 2021 e 2022 como contexto histórico — **22.686 respostas no total** — em um pipeline AWS no padrão Medallion (S3 Bronze/Silver/Gold, Glue Jobs em PySpark, Glue Data Catalog e Athena).

Os resultados desenham um mercado em consolidação técnica e em aceleração de IA. Python atingiu **92,0%** de adoção (era 44,4% em 2019) e SQL, **84,2%**, formando o núcleo técnico inegociável. A AWS lidera a corrida de cloud com **48,3%** (Azure 34,8%, GCP 30,9%). Entre gestores, IA generativa como prioridade máxima ou entre as principais saltou de **36,2% em 2023 para 60,6% em 2025/26**, enquanto "não é prioridade" caiu de 28,8% para 11,3%. No uso individual, a modalidade "empresa paga a solução de GenAI" saltou de **6,4% para 42,4%** — a IA deixou de ser iniciativa pessoal e virou política corporativa.

Nos recortes de talento, a escada salarial mediana estimada em 2025/26 vai de **R\$ 3.501 (Júnior) a R\$ 18.001 (Especialista/Staff+)**. A participação feminina segue baixa (22,0% em 2025/26, após pico de 24,8% em 2022) e o gap salarial concentra-se no nível Sênior (**-28,6% na mediana**). O modelo de trabalho é fator crítico de atração: apenas 1,9% desejam regime 100% presencial. As recomendações finais — contratação, capacitação e investimento — derivam diretamente desses números.

A Tabela 1 sintetiza a conversão direta de evidência em decisão — o mapa mínimo para o comitê executivo:

Tabela 1 – Da evidência à decisão (síntese executiva).

Evidência (2025/26)	Decisão recomendada
Python 92,0% e SQL 84,2% de adoção	Trilha-base obrigatória Python + SQL
AWS lidera cloud com 48,3%	Priorizar stack e certificações AWS
IA como prioridade top-2: 36,2% → 60,6%	Acelerar programa de GenAI com governança
GenAI paga pela empresa: 6,4% → 42,4%	Licenciamento corporativo + política de uso
Gap salarial de -28,6% no nível Sênior	Metas de diversidade na promoção, não só na entrada
Apenas 1,9% desejam modelo 100% presencial	Política declarada de flexibilidade (EVP)

Artefatos e Links do Projeto

Os artefatos avaliáveis deste projeto estão relacionados abaixo.

- Repositório GitHub: <https://github.com/lgmricardo/Techchallenge3-G12>
- Pacote técnico (zip): notebooks 01–05 executados, Glue Jobs, config (de-para + premissas), gráficos e camada Gold em CSV.
- Diagrama de arquitetura: architecture/aws_architecture.drawio (editável) e Figura 1 deste relatório.
- Guia operacional AWS: docs/aws_step_by_step_guide.md (do acesso ao Learner Lab às evidências E01–E08).
- Evidências de execução na AWS: pasta evidence do repositório (prints E01–E08 do console).

Nota sobre caminhos citados: os caminhos de arquivo mencionados ao longo deste relatório (por exemplo, src/, architecture/, datalake/, consumption/) referem-se à estrutura do repositório GitHub listado acima. No pacote técnico (zip) que acompanha esta entrega, os mesmos arquivos estão organizados nas pastas 1_material_executivo/, 2_diagrama_arquitetura/ e 3_scripts_e_codigos/, descritas nesta lista.

A Tabela 2 mapeia cada requisito técnico do enunciado à sua implementação e evidência correspondente neste projeto:

Tabela 2 – Matriz de aderência ao enunciado (Tech Challenge Fase 3).

Requisito do enunciado	Onde está implementado	Evidência
3 últimas pesquisas (2023, 2024, 2025/26)	Núcleo obrigatório do pipeline; edições 2019–2022 usadas só em séries longas de contexto	Notebook 01; Seção 2.1 deste relatório
AWS Academy Lab	S3 (Bronze/Silver/Gold) + 2 Glue Jobs + Glue Data Catalog + Athena	Evidências E01–E08
Diagrama em Draw.io	Diagrama editável, incluído no material executivo	architecture/aws_architecture.drawio (repositório); Figura 1
Ingestão / camada Bronze	6 CSVs brutos, partição ano=YYYY, imutável	Notebook 01; evidência E03
Tratamento / camada Silver	De-para versionado, harmonização de schema em PySpark	Notebook 02; evidência E06a
Transformação / camada Gold	21 tabelas analíticas orientadas às 7 perguntas de negócio	Notebook 03; evidência E06b
Catologação	Glue Data Catalog, banco stateofdata	Notebook 04 (DDL/Crawler); evidência E07
Consultas analíticas (Athena)	7 consultas SQL, uma por pergunta de negócio	Notebook 04; evidência E08 (q1–q7)
Spark / PySpark	Todo o processamento das camadas Bronze → Silver → Gold	Notebooks 02–04; jobs/*.py
Gráficos (DataViz)	15 gráficos com fonte, edição e n declarados	Notebook 05; G01–G15
Storytelling / material executivo	Deck com narrativa, indicadores e recomendações	executive_deck.pptx
Recomendações estratégicas	8 ações priorizadas com evidência associada	Slide de recomendações do material executivo

1. Compreensão do Problema

1.1 Contexto e motivação

Uma instituição financeira de grande porte pretende expandir sua área de Dados, Analytics e IA e precisa de um retrato confiável do mercado brasileiro para calibrar três decisões: **quem contratar, o que capacitar e onde investir**. A pesquisa State of Data Brasil, conduzida pela comunidade Data Hackers em parceria com a Bain & Company, é a fonte pública mais completa sobre o perfil desses profissionais — e suas bases brutas exigem um fluxo real de engenharia de dados antes de gerar informação de negócio, o que este projeto implementa de ponta a ponta em ambiente AWS.

1.2 Pergunta norteadora e desdobramentos

Como a evolução do mercado brasileiro de dados (perfil profissional, senioridade, remuneração, diversidade, tecnologias e adoção de IA), observada nas três últimas edições da pesquisa State of Data Brasil, deve orientar as estratégias de contratação, capacitação e investimento de uma instituição financeira de grande porte?

A pergunta desdobra-se nas sete questões do enunciado, respondidas nas seções 5 a 11:

- 1. Como está estruturado o mercado brasileiro de Dados? (Seção 5)
- 2. Quais perfis profissionais são mais valorizados? (Seção 6)
- 3. Qual é o cenário de diversidade de gênero? (Seção 7)
- 4. Quais tecnologias apresentam maior adoção? (Seção 8)
- 5. Qual é o índice de adoção de IA e seu impacto? (Seção 9)
- 6. Existem diferenças entre regiões, senioridades e modelos de trabalho? (Seções 6, 7 e 10)
- 7. Quais oportunidades e desafios para quem investe em Dados e IA? (Seção 11)

1.3 Visão geral da metodologia

O método segue quatro etapas: (i) ingestão das seis edições no S3 (camada Bronze, imutável); (ii) harmonização de esquemas e categorias em PySpark, com de-para versionado e premissas registradas (Silver); (iii) agregações analíticas por tema (Gold, 21 tabelas); e (iv) consultas SQL no Athena e geração de gráficos sobre agregados. Todas as proporções de questões multirresposta usam como denominador os **respondentes válidos de cada questão**, e comparações entre edições ocorrem somente após a harmonização — evitando conclusões espúrias por mudança de questionário.

2. Fontes de Dados, Governança e Premissas

2.1 Bases utilizadas e volumetria

Foram utilizadas as seis edições públicas da pesquisa (Kaggle). As três últimas formam o núcleo obrigatório; as demais entram apenas como série histórica em indicadores de longo prazo (gênero, linguagens e cloud), decisão registrada como premissa P1.

Nota: embora a descrição do dataset no edital tome 2021 como referência histórica padrão, a edição de 2019 foi mantida exclusivamente para estender a série temporal dos indicadores de gênero, linguagens e cloud.

Tabela 3 – Bases da pesquisa State of Data Brasil utilizadas no projeto.

Edição	Volumetria (linhas × colunas)	Papel no projeto	Padrão de schema
2025/26	3.495 × 388	Núcleo obrigatório	1.a_idade
2024	5.217 × 403	Núcleo obrigatório	1.a_idade
2023	5.293 × 399	Núcleo obrigatório	tupla ('P1_a', 'Idade')
2022	4.271 × 353	Contexto histórico	tupla
2021	2.645 × 356	Contexto histórico	tupla
2019	1.765 × 170	Contexto histórico	tupla (schema distinto)

2.2 Divergência de esquemas e harmonização (de-para)

A edição 2023 usa cabeçalhos em formato de tupla; 2024 e 2025/26 usam notação hierárquica; e códigos de colunas mudam de posição entre anos (a coluna de AWS, por exemplo, é *4.e.1* em 2025/26, *4.h.1* em 2024 e *P4_h_2* em 2023). O de-para completo — 69 variáveis por edição — está versionado em `src/config/column_mapping.json` (repositório GitHub) e é aplicado no Glue Job 1. A tabela a seguir ilustra o padrão.

Tabela 4 – Exemplos do de-para de colunas entre edições (mapa completo versionado no repositório).

Variável harmonizada	2025/26	2024	2023
genero	1.b_genero	1.b_genero	('P1_b ', 'Genero')
faixa_salarial	2.h_faixa_salarial	2.h_faixa_salarial	('P2_h ', 'Faixa salarial')
cloud_aws	4.e.1_Amazon Web Services (AWS)	4.h.1_Amazon Web Services (AWS)	('P4_h_2 ', 'Amazon Web Services (AWS)')
layoff	2.p_..._layoff_em_2025	2.q_..._layoff_em_2024	('P2_q ', 'Empresa ... layoff em 2023')
prioridade_ia	3.e_ai_generativa_..._prioridade?	3.e_ai_generativa_..._prioridade?	('P3_e ', 'AI Generativa é uma prioridade...')

2.3 Premissas versionadas

Toda decisão metodológica com impacto nos números foi registrada como premissa auditável:

Tabela 5 – Premissas analíticas versionadas do projeto.

ID	Premissa	Decisão registrada
P1	Escopo das edições	Núcleo = 2023/2024/2025-26; 2019/2021/2022 apenas em séries longas (gênero, linguagens, cloud)
P2	Tratamento de dados sensíveis	Base pública anonimizada na origem; análise exclusivamente agregada; sem supressão adicional de células
P3	Estimativa salarial	Ponto médio da faixa salarial: 'de X a Y' $\rightarrow (X + Y) \div 2$; 'Menos de X' $\rightarrow X \div 2$; 'Acima de X' $\rightarrow X \times 1,125$.
P4	Correção de typo (2025/26)	"de R\$ 25.001/mês a R\$ 3000/mês" $\rightarrow$ teto interpretado como R\$ 30.000 (regra: $\text{teto} < \text{pisso} \Rightarrow \text{teto} \times 10$); 1 registro afetado
P5	Harmonização de cargos	Agrupamento em cargo_grupo por famílias funcionais; Engenharia de Dados e Arquitetura de Dados unificadas, seguindo o padrão de rótulo da própria edição 2023 da pesquisa.
P6	Multirresposta	Percentuais calculados sobre respondentes válidos da questão, nunca sobre o total da base
P7	Booleanos heterogêneos	`1/0`, `True/False` e `TRUE/FALSE` (padrão 2024) normalizados para inteiro 1/0
P8	Corte de exibição por tamanho de grupo	Recortes com $n < 30$ não são exibidos em gráficos e tabelas (corte de exibição, não de processamento). Justificativa medida na Seção 2.6: abaixo desse limite a mediana de faixa oscila por várias faixas sob reamostragem. Afeta 2 dos 12 grupos de cargo de 2025/26 (25 respondentes, 1,0%) e a região Norte no nível Sênior

2.4 LGPD e conformidade

As bases são publicadas anonimizadas na origem pelo Data Hackers. O projeto opera exclusivamente com estatísticas agregadas, sem qualquer tentativa de reidentificação (vedada pela LGPD), cita fonte, edição e n amostral em todos os gráficos e tabelas, e adota os controles de segurança da Seção 3.3 — atendendo ao bloco regulatório definido para o projeto.

Esse tratamento cobre o dataset público usado neste projeto. Se a instituição financeira adotar a mesma arquitetura sobre seus próprios dados de RH e candidatos — não públicos, não anonimizados — a base legal, o direito do titular, a retenção e os controles de segurança cibernética (Resolução BACEN 4.658/2021, aplicável a instituições financeiras) precisam ser reavaliados; esse é um requisito da fase de implementação, fora do escopo analítico deste relatório.

2.5 Análise Exploratória e Qualidade dos Dados

Antes de qualquer análise, o núcleo harmonizado (silver_core, $n = 14.005$: 5.293 em 2023, 5.217 em 2024 e 3.495 em 2025/26) passou por avaliação exploratória de qualidade. **Unicidade:** foram identificadas apenas 3 ocorrências de token repetido (2 em 2024 e 1 em 2025/26; 0,02% do núcleo), mantidas na base por impacto estatístico nulo. **Nulos:** os valores ausentes são majoritariamente estruturais — decorrem do fluxo condicional do questionário, não de falha de coleta — e por isso nenhuma imputação foi aplicada; cada análise usa como denominador os respondentes válidos da

questão (premissa P6). A Tabela 5 resume o preenchimento das variáveis-chave e o motivo estrutural de cada lacuna.

Tabela 6 – Preenchimento das variáveis-chave do núcleo (n = 14.005) e origem estrutural dos nulos.

Variável	Preenchida	Motivo estrutural do nulo
genero / atuacao	100,0%	Perguntas universais
faixa_salarial, modelo_atual, satisfeito	91,7%	Respondidas apenas por quem tem vínculo ativo (8,3% desempregados/estudantes)
nivel e cargo	72,7%	Respondidas apenas por contribuidores individuais empregados
cargo_gestor	19,1%	Respondida apenas pelos 2.668 gestores
prioridade_ia	18,5%	Bloco exclusivo de gestores

2.6 Nota metodológica: abordagem descritiva e escolhas de representação

Este relatório adota deliberadamente análise **exclusivamente descritiva**. Como a amostra é por conveniência — sem desenho probabilístico nem pesos amostrais —, intervalos de confiança e testes de hipótese não teriam validade inferencial para o universo de profissionais do país; incluí-los seria decoração estatística, não rigor. Em substituição, o relatório (i) declara o n de cada recorte, (ii) destaca apenas diferenças de magnitude expressiva e consistentes entre edições, e (iii) trata toda leitura como 'entre os respondentes da pesquisa'.

As escolhas de representação seguem o mesmo princípio: **barras** para comparações categóricas (percepção de proporção por comprimento), **linhas** para evolução temporal, **mediana** como medida central pela robustez à assimetria típica de distribuições salariais, e vedação a gráficos de pizza com mais de três categorias. As variações são expressas em pontos percentuais (p.p.) e razões de crescimento (x) em vez de CAGR, pois taxas de adoção são limitadas a 100% e métricas compostas induziriam leitura enganosa de aceleração. Por fim, todos os valores monetários deste relatório são nominais, sem deflacionamento: comparações entre edições refletem a remuneração declarada em cada ano, não o poder de compra equivalente. A mediana calculada sobre faixas tem ainda baixa resolução — como as faixas chegam a R\$ 4.000 de amplitude, grupos com distribuições diferentes podem exibir a mesma mediana; quando esse limite é relevante para a conclusão, o relatório complementa a mediana com a média dos pontos médios, que discrimina dentro da faixa. Desse mesmo limite decorre a premissa P8: recortes por grupo com menos de 30 respondentes não são exibidos nos gráficos e tabelas. O corte não é convenção adotada por comodidade, e sim consequência medida da baixa resolução do instrumento. Reamostrando os próprios dados de 2025/26 (3.000 reamostragens com reposição), a mediana do grupo Estatística/Economia (n = 9) oscila entre R\$ 1.500 e R\$ 18.000 — atravessa sete faixas salariais —, e a de Professor/Pesquisador (n = 16) oscila entre R\$ 5.000 e R\$ 16.000. Acima do corte, a oscilação cai para uma faixa: Produto (n = 33) varia entre R\$ 10.000 e R\$ 18.113 e os grupos com mais de cem respondentes se estabilizam em uma única faixa. Exibir uma mediana de nove respondentes ao lado de outra de 599 sugeriria ao leitor uma precisão que o dado não tem. O corte é de exibição, não de processamento: nenhum registro é descartado do pipeline, os grupos pequenos permanecem íntegros na camada Gold e são nomeados no texto sempre que ficam de fora. Na prática, o critério afeta 2 dos 12 grupos de cargo de 2025/26 — 25 respondentes, 1,0% da base com cargo declarado — e, no recorte regional por senioridade, apenas a região Norte (n = 12 no nível Sênior).

Validação das medianas críticas: as medianas usadas nas Seções 6 e 7 (prêmio de senioridade, gap salarial por gênero) foram conferidas por cálculo exato (particionamento e ordenação linha a linha), não pela função de percentil aproximado do Athena/Trino. A função aproximada (APPROX_PERCENTILE/percentile_approx, algoritmo T-digest) diverge da mediana exata quando a coluna tem poucos valores distintos e muito repetidos — exatamente o caso de salario_pm, derivada do ponto médio de faixas (Premissa P3). Essa divergência foi observada e corrigida durante a validação deste projeto (ex.: Sênior 2023 retornava R\$ 11.498 pela função aproximada contra R\$

10.001 pelo cálculo exato, confirmado via computação direta em PySpark) — os números citados neste relatório são todos o valor exato.

3. Arquitetura da Solução AWS

3.1 Visão geral

A solução implementa o padrão Medallion em ambiente AWS Academy Lab: dados brutos imutáveis (Bronze), dados harmonizados e tipados (Silver) e agregados prontos para consumo analítico (Gold), com catalogação central e consulta SQL serverless. A Figura 1 apresenta o fluxo completo, numerado nas onze etapas do desenho oficial em Draw.io.

Arquitetura da Solução — Tech Challenge Fase 3 · State of Data Brasil (Data Hackers/Bain)

Padrão Medallion (Bronze / Silver / Gold) no AWS Academy Lab · S3 + Glue + Athena · Grupo: Efraim Oliveira · Érica Tansie · Ricardo Moraes · Rodrigo Bernardino · Thiago Galvão

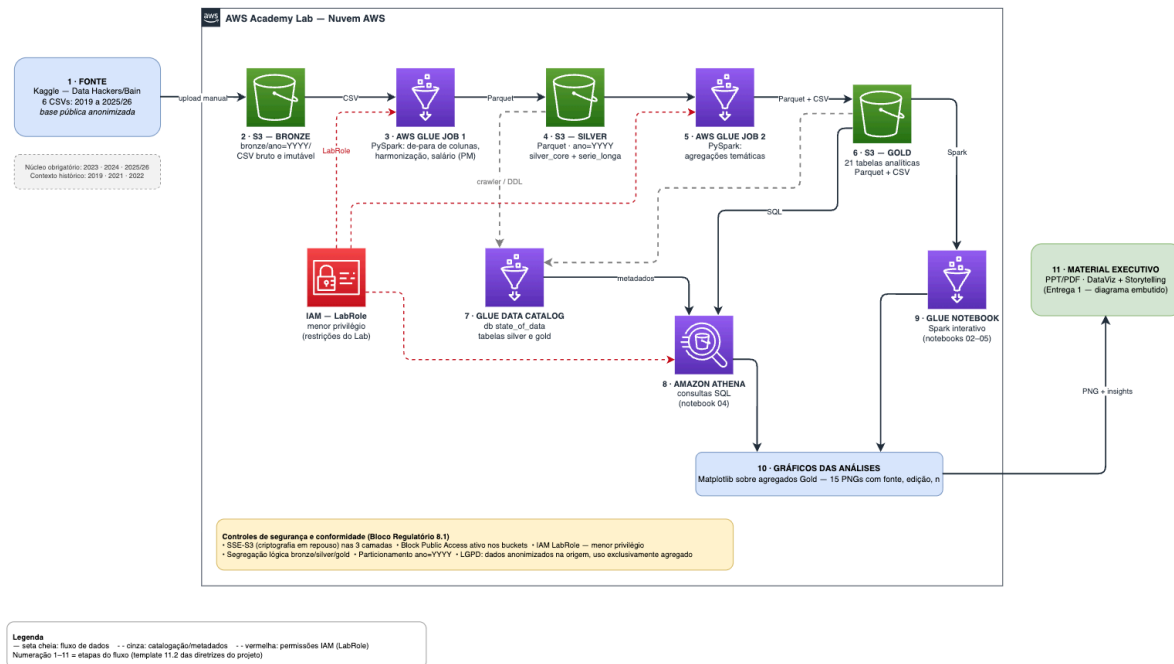


Figura 1 — Arquitetura da solução AWS — fluxo Kaggle → S3 (Bronze/Silver/Gold) → Glue → Athena → consumo.

3.2 Camadas e responsabilidades

Tabela 7 — Camadas de dados, conteúdo e tecnologia.

Camada	Conteúdo	Formato	Tecnologia
Bronze	6 CSVs originais, partição ano=YYYY, imutável	CSV	S3
Silver	silver_core (3 edições, 69 colunas) e silver_serie_longa (6 edições)	Parquet	S3 + Glue Job 1 (PySpark)
Gold	21 tabelas analíticas agregadas por tema	Parquet + CSV	S3 + Glue Job 2 (PySpark)
Catálogo	db stateofdata — tabelas silver e gold	metadados	Glue Data Catalog
Consumo	Consultas Q1–Q7 e gráficos executivos	SQL / PNG	Athena · Matplotlib

Alternativas consideradas. A escolha de Glue — não EMR/Databricks — e Athena — não Redshift — segue o mesmo critério de adequação ao volume e ao formato do Lab, não preferência de

fornecedor. Glue é serverless, com custo por execução e sem cluster para provisionar/desligar, adequado a um pipeline batch de poucos minutos; EMR/Databricks fariam sentido a partir de um volume ou de uma cadência de execução que este projeto não tem. Athena é serverless e cobra por TB escaneado — para um datalake desta escala (dezenas de MB), o custo por consulta é irrelevante e não há cluster provisionado ocioso entre consultas, ao contrário de um Redshift dedicado.

3.3 Segurança

Controles aplicados: criptografia em repouso SSE-S3 nas três camadas; Block Public Access ativo no bucket; IAM LabRole com menor privilégio (restrição do próprio Lab); segregação lógica bronze/silver/gold; e particionamento ano=YYYY, que reduz varredura e custo por consulta no Athena.

3.4 Execução no AWS Academy Lab e evidências

O pipeline foi desenvolvido e validado de ponta a ponta com os dados reais e portado para o Lab em dois Glue Jobs idempotentes (parâmetro --BUCKET). O guia operacional do grupo documenta o passo a passo do console e a coleta das evidências **E01–E08** (Learner Lab ativo, bucket seguro, Bronze com as seis edições, jobs Succeeded, Parquet nas camadas, catálogo e queries no Athena), que devem ser anexadas na pasta evidence do repositório.

4. Pipeline de Dados

4.1 Ingestão (Bronze)

Os seis CSVs são renomeados para o padrão state_of_data_AAAA.csv e carregados em datalake/bronze/ano=AAAA/. A camada é tratada como imutável: nenhuma transformação ocorre sobre os arquivos originais, preservando a auditabilidade da origem.

4.2 Transformação Bronze → Silver

O Glue Job 1 aplica o de-para de colunas, normaliza variáveis binárias (incluindo os booleanos TRUE/FALSE exclusivos da edição 2024 — premissa P7), harmoniza categorias (cargos, modelos de trabalho, prioridade de IA), calcula o ponto médio salarial (premissas P3 e P4) e grava Parquet particionado. A reconciliação de volumetria é verificada por asserções automáticas ao final do job:

Tabela 8 – Reconciliação Bronze × Silver por edição (asserções do Glue Job 1).

Edição	Linhas esperadas	Linhas na Silver	Status
2019	1.765	1.765	OK
2021	2.645	2.645	OK
2022	4.271	4.271	OK
2023	5.293	5.293	OK
2024	5.217	5.217	OK
2025/26	3.495	3.495	OK

4.3 Transformação Silver → Gold

O Glue Job 2 materializa 21 tabelas agregadas (englobando respondentes, cargos, senioridade, salários por nível e por cargo, participação e gaps de gênero, tecnologias, prioridade de IA, uso de GenAI, regiões, modelos de trabalho, termômetro de mercado, intenção de mudança, critérios de escolha de emprego e desafios de gestores), cada uma gravada em Parquet (consulta) e CSV (consumo direto pelos gráficos). Os percentuais de questões multiresposta usam como denominador a base de respondentes válidos de cada pergunta (premissa P6).

4.4 Catalogação e consultas

A camada Gold é gerada nativamente via PySpark — pela execução automatizada do Glue Job 2 ou, de forma interativa e equivalente, pelo notebook 03 rodando no Glue Notebook. As tabelas Silver e Gold são registradas no Glue Data Catalog (crawler ou DDL com MSCK REPAIR para as partições). O Amazon Athena é empregado como motor de consulta ad-hoc e validação de schema sobre esse catálogo, servindo para auditoria e execução das queries analíticas (Q1 a Q7).

4.5 Métricas de qualidade do pipeline

A Tabela 8 consolida os indicadores de execução e qualidade do fluxo — a evidência objetiva de que nenhum registro foi perdido ou inventado entre a origem e as análises.

Tabela 9 – Métricas de execução e qualidade do pipeline.


Métrica	Valor
Linhas ingeridas (Bronze, 6 edições)	22.686
Linhas no núcleo harmonizado (Silver core)	14.005
Registros descartados	0 (reconciliação 1:1)
Tokens repetidos identificados	3 (0,02%), mantidos — impacto estatístico nulo
Colunas harmonizadas por edição (de-para)	69
Correções de dado documentadas	1 tipo de faixa salarial (P4); booleanos TRUE/FALSE de 2024 normalizados (P7)
Tabelas analíticas na camada Gold	21
Asserções de volumetria/schema	100% aprovadas nas 6 edições

A duração de execução dos Glue Jobs 1 e 2 é documentada pelas evidências E04 e E05 (capturas do console AWS com o tempo de cada run), anexadas à pasta evidence do repositório.

5. O Mercado Brasileiro de Dados (Pergunta 1)

5.1 Base de respondentes

A série reúne 22.686 respostas em seis edições (Figura 2). A queda de volume em 2025/26 (3.495 respostas) reflete a adesão à pesquisa, não o tamanho do mercado; por isso, todo o relatório trabalha com proporções, nunca com valores absolutos entre edições (premissa de leitura fundamental).




Fonte: State of Data Brasil — Data Hackers/Bain | Edições 2019 a 2025/26 | n = 22.686 · cinza: contexto histórico | azul: núcleo obrigatório

Figura 2 – Respondentes por edição da pesquisa (cinza: contexto histórico; azul: núcleo obrigatório).

5.2 Perfis profissionais

A distribuição por grupos de cargo em 2025/26 (Figura 3 e Tabela 9) mostra a consolidação de quatro grandes famílias — Análise de Dados, Engenharia/Arquitetura, Ciência de Dados e BI — com presença crescente de Analytics Engineer e ML/AI Engineer, cargos que praticamente não existiam nas primeiras edições.



Fonte: State of Data Brasil — Data Hackers/Bain | Edição 2025/26 | n = 2.501 · top 9 grupos · empate real: Eng. de Software e ML/AI Engineer (n = 106 cada)

Figura 3 – Participação por grupo de cargo entre contribuidores individuais — 2025/26 (top 9).

Tabela 10 – Principais grupos de cargo — 2025/26 (contribuidores individuais, top 9).


Grupo de cargo	n	%
Análise de Dados	599	24,0%

Grupo de cargo	n	%
Engenharia/Arquitetura de Dados	430	17,2%
Ciência de Dados	424	17,0%
Outros	287	11,5%
Business Intelligence	215	8,6%
Análise de Negócios	141	5,6%
Analytics Engineer	135	5,4%
Eng. de Software	106	4,2%
ML/AI Engineer	106	4,2%

Registra-se um empate real de amostragem entre Eng. de Software e ML/AI Engineer (n = 106 cada; 4,2%) — verificado na camada Gold, sem qualquer troca de rótulos ou agrupamento acidental. O ML/AI Engineer, embora ainda pequeno em volume, é o grupo de maior mediana salarial do mercado (R\$ 18.001 — Seção 6.2), o que o torna o perfil mais estratégico a monitorar. O grupo “Outros” (11,5%) também não é residual arbitrário: dos 287 registros, 206 correspondem a respondentes que selecionaram a própria opção “Outra Opção” do questionário, 55 a Analista de Suporte/Analista Técnico e 26 a Outras Engenharias (não desenvolvimento). Funções como Professor/Pesquisador e Estatístico recebem categoria própria no agrupamento (premissa P5) e ficam fora da Tabela 9 apenas por volume inferior ao corte do top 9.

5.3 Senioridade

A pirâmide de senioridade (Figura 4) mostra um mercado que amadureceu, mas exige leitura cuidadosa: em 2025/26 a pesquisa criou a categoria Especialista/Staff+, que absorveu parte de quem antes se declarava Sênior. Por isso a barra “Sênior” aparece menor em 2025/26 (34,3%) do que em 2024 (41,2%), sem que isso signifique retração do topo. Somando as duas categorias, a evolução é inequívoca: os profissionais de nível Sênior ou acima passaram de 36,8% (2023) para 41,2% (2024) e 48,3% (2025/26) — avanço de 11,5 pontos percentuais em duas edições. Na base, o movimento é simétrico: os Júnior recuaram de 27,1% para 20,7%. Para o cliente, isso significa concorrência mais dura por profissionais experientes e oportunidade real em programas de formação de base.




Fonte: State of Data Brasil — Data Hackers/Bain | Edições 2023, 2024, 2025/26 | n = 10.176 · Especialista/Staff+ criado apenas em 2025/26; comparar o topo pela soma Sênior+ (36,8% → 41,2% → 48,3%)

Figura 4 – Pirâmide de senioridade por edição (Especialista/Staff+ existe apenas em 2025/26).

6. Perfis Valorizados e Remuneração (Pergunta 2)

6.1 A escada salarial por senioridade

A mediana estimada por ponto médio de faixa (premissa P3) em 2025/26 é de R\$ 3.501 (Júnior), R\$ 7.001 (Pleno), R\$ 14.001 (Sênior) e R\$ 18.001 (Especialista/Staff+) — cada degrau até o nível Sênior aproximadamente dobra a remuneração (Figura 5 e Tabela 10). Um ponto merece destaque justamente por não aparecer: entre 2023 e 2025/26 as medianas de Júnior (R\$ 3.501) e Pleno (R\$ 7.001) permaneceram idênticas em termos nominais, enquanto a do nível Sênior subiu de R\$ 10.001 para R\$ 14.001. Como os valores não são deflacionados, estabilidade nominal por três anos significa perda de poder de compra real na base da pirâmide: o mercado não apenas encareceu o topo — concentrou nele todo o ganho do período.



Fonte: State of Data Brasil — Data Hackers/Bain | Edições 2023, 2024, 2025/26 | n = 10.176 · valores nominais, sem deflacionamento


Figura 5 – Salário mediano estimado por senioridade e edição (ponto médio de faixa — premissa P3).

Tabela 11 – Salário mediano estimado (R\$/mês, ponto médio) por senioridade e edição.

Nível	2023	2024	2025/26
Júnior	R\$ 3.501	R\$ 3.501	R\$ 3.501
Pleno	R\$ 7.001	R\$ 7.001	R\$ 7.001
Sênior	R\$ 10.001	R\$ 14.001	R\$ 14.001
Especialista/Staff+	—	—	R\$ 18.001

6.2 Prêmio por especialização

Entre cargos (Figura 6), os maiores prêmios de mediana em 2025/26 estão nas funções de engenharia e ciência aplicada — exatamente os perfis que constroem plataforma e produtos de IA. Para a instituição financeira, o recado é direto: o orçamento de contratação deve considerar bandas distintas por família de cargo, não uma tabela única de “profissional de dados”.



Fonte: State of Data Brasil — Data Hackers/Bain | Edição 2025/26 | n = 2.189 · grupos com n ≥ 30

Figura 6 – Salário mediano estimado por grupo de cargo — 2025/26 (grupos com n ≥ 30).

6.3 Controle por senioridade: o prêmio de cargo é real?

A comparação de medianas entre grupos de cargo (Figura 6) carrega um risco metodológico conhecido: **a composição de senioridade não é homogênea entre os grupos**. Entre os respondentes de 2025/26, a proporção de profissionais Sênior ou acima varia de 35,3% (Business Intelligence) a 65,1% (ML/AI Engineer) — e chega a 87,9% em Produto. Sem controle, parte do que se leria como “prêmio de cargo” seria, na verdade, efeito de um grupo simplesmente conter mais profissionais experientes. Aplicou-se, portanto, o mesmo tratamento usado na análise de gênero (Seção 7.2): fixar o nível de senioridade e comparar apenas dentro dele.

A Tabela 11 apresenta o recorte do nível Sênior — o mais populoso da base e o mais relevante para a estratégia de contratação do cliente. **A hierarquia de três patamares se mantém integralmente**, o que indica que a diferença reflete o cargo em si, e não a composição de senioridade dos grupos: ML/AI Engineer no topo, um bloco intermediário de funções técnicas e de plataforma, e os perfis analíticos de negócio no patamar inferior. O mesmo padrão se repete nos níveis Júnior e Pleno. Estes números estão materializados na tabela Gold gold_salary_by_role_seniority, adicionada à camada Gold para tornar este recorte auditável e reproduzível a partir do pipeline.

Tabela 12 – Salário mediano por grupo de cargo no nível Sênior — 2025/26 (controle de composição).

Grupo de cargo	% Sênior+ no grupo	Mediana (nível Sênior)	n (Sênior)
ML/AI Engineer	65,1%	R\$ 18.001	42
Analytics Engineer	61,5%	R\$ 14.001	59
Engenharia/Arquitetura de Dados	62,1%	R\$ 14.001	192
Ciência de Dados	51,7%	R\$ 14.001	147
Eng. de Software	51,9%	R\$ 14.001	41
Produto (DPM/PM)	87,9%	—	—
Análise de Dados	40,6%	R\$ 10.001	184
Business Intelligence	35,3%	R\$ 10.001	59
Análise de Negócios	46,8%	R\$ 10.001	48

Nota: “Sênior+” inclui Especialista/Staff+ no numerador do percentual; as colunas de mediana e n consideram apenas o nível Sênior stricto sensu (Especialista/Staff+ é tratado à parte na Tabela 10). Em Produto (DPM/PM), mediana e n aparecem como “—”: o subconjunto Sênior tem apenas 19


peças, abaixo do corte de estabilidade da Premissa P8 ($n \geq 30$); o percentual Sênior+ (87,9%) permanece porque é calculado sobre os 33 respondentes do grupo total, que atende ao corte.

O controle também corrige duas leituras que a visão agregada induziria ao erro. Primeira: **Ciência de Dados e Engenharia/Arquitetura de Dados são equivalentes** quando o nível é fixado (R\$ 14.001 no Sênior, R\$ 18.001 no Especialista/Staff+); a diferença observada na Figura 6 decorre da composição (51,7% contra 62,1% de sênior+), não do cargo em si. Segunda: a mediana bruta **subestima o topo do ML/AI Engineer**, pois o grupo carrega 19,8% de profissionais Júnior — no nível Especialista/Staff+ sua mediana aproxima-se de R\$ 27.500 ($n = 27$). Para o cliente, a consequência prática é direta: bandas salariais devem ser definidas pelo cruzamento cargo × senioridade, nunca por cargo isoladamente.

7. Diversidade de Gênero (Pergunta 3)

7.1 Participação feminina

A participação feminina foi de 18,5% em 2019 ao pico de 24,8% em 2022 e recuou para 22,0% em 2025/26 — retração de 2,8 pontos percentuais (p.p.) frente ao pico (Figura 7). O avanço da década estagnou: um em cada cinco profissionais de dados é mulher.




Fonte: State of Data Brasil — Data Hackers/Bain | Edições 2019 a 2025/26 | $n = 22.674$ · pico de 24,8% em 2022; retração de 2,8 p.p. até 2025/26

Figura 7 – Participação feminina entre os profissionais de dados — série 2019 a 2025/26.

7.2 Gap salarial controlado por senioridade

A comparação bruta de salários seria enganosa; controlando por senioridade (Figura 8 e Tabela 12), as medianas são iguais nos níveis Júnior e Pleno, mas abre-se um gap de **-28,6% no nível Sênior** — R\$ 4.000 mensais na mediana (R\$ 14.001 vs R\$ 10.001) — e diferença relevante também no topo (Especialista/Staff+). O problema do mercado não é a porta de entrada; é a progressão — e a Seção 7.4 decompõe esse gap em suas duas causas.



Fonte: State of Data Brasil — Data Hackers/Bain | Edição 2025/26 | n = 2.485 · gap de -28,6% concentrado no nível Sênior

Figura 8 – Salário mediano por gênero, controlado por senioridade — 2025/26.

Tabela 13 – Mediana salarial estimada por gênero e nível — 2025/26.

Nível	Feminino	Masculino	Diferença (F abaixo de M)
Júnior	R\$ 3.501	R\$ 3.501	0,0%
Pleno	R\$ 7.001	R\$ 7.001	0,0%
Sênior	R\$ 10.001	R\$ 14.001	28,6%
Especialista/Staff+	R\$ 14.001	R\$ 18.001	22,2%

7.3 Liderança

Entre respondentes empregados de 2025/26, 19,1% das mulheres ocupam posição de gestão, contra 23,6% dos homens — a diferença na liderança acompanha o gap de progressão da subseção anterior e indica onde políticas de D&I têm maior alavancagem: promoção e retenção, não apenas contratação.

7.4 Decompondo o gap: composição de cargo e diferença residual

O controle por senioridade da subseção anterior deixa uma pergunta em aberto: dentro do nível Sênior, homens e mulheres ocupam os mesmos cargos? A resposta é não — e isso decompõe o gap em duas causas distintas.

Causa 1 — composição de cargo. Entre os profissionais Sênior, as mulheres estão bem menos representadas em Engenharia/Arquitetura de Dados (14,0% delas, contra 24,7% dos homens), justamente a família de maior remuneração, e mais concentradas em Análise de Dados (23,6% contra 21,0%), de patamar inferior. Parte do gap agregado é, portanto, efeito de acesso desigual às trilhas mais bem pagas. Estes números estão materializados na tabela `Gold gold_gender_role_seniority`, adicionada à camada Gold para tornar este recorte auditável e reproduzível a partir do pipeline.

Causa 2 — diferença residual dentro do mesmo cargo. O gap não desaparece quando cargo e senioridade são fixados simultaneamente, mas deixa de ser uniforme: em Ciência de Dados e Análise de Dados as medianas são idênticas entre gêneros; em Engenharia/Arquitetura de Dados,


ao contrário, a mediana feminina fica 28,6% abaixo da masculina no mesmo nível. Estes valores (R\$ 10.001 feminino, R\$ 14.001 masculino) também estão na coluna `salario_mediano_pm` de `gold_gender_role_seniority`, tornando a Causa 2 igualmente auditável a partir do pipeline.

Leitura adotada. O projeto adota as duas causas como complementares, atribuindo prioridade à Causa 1 por dois motivos: ela se apoia em amostra mais robusta — entre os sêniores de Engenharia/Arquitetura há 167 homens e apenas 25 mulheres — e é diretamente acionável por política de atração e mobilidade interna. A Causa 2 é declarada como sinal relevante, porém não conclusivo: com base feminina reduzida em cada célula de cargo (25 em Engenharia, 15 em Business Intelligence), e sem inferência estatística aplicável a esta amostra (Seção 2.6), ela indica onde investigar, não o que afirmar. A recomendação de diversidade da Seção 12.1 contempla as duas frentes.

8. Tecnologias com Maior Adoção (Pergunta 4)

8.1 Linguagens

Python saltou de 44,4% (2019) para **92,0%** (2025/26) — avanço de 47,6 p.p., um crescimento relativo de 2,1 vezes — e SQL mantém-se em 84,2%; este par forma a alfabetização mínima do mercado (Figura 9). R recuou para nicho estatístico (15,6%). Currículos de capacitação interna devem tratar Python + SQL como pré-requisito, não como diferencial.




Fonte: State of Data Brasil — Data Hackers/Bain | Edições 2019 a 2025/26 | n = 16.060 · questão de múltipla resposta

Figura 9 – Adoção de linguagens no trabalho — série 2019 a 2025/26 (multirresposta).

8.2 Cloud

A AWS lidera com 48,3% de adoção, seguida de Azure (34,8%) e GCP (30,9%) — Figura 10. Para o cliente, a disponibilidade de talentos por provedor reduz custo e prazo de contratação; a própria arquitetura deste projeto (S3 + Glue + Athena) está alinhada ao provedor dominante. Uma ressalva de leitura: o rótulo do bloco de cloud diverge entre edições — a base de 2023 registra a pergunta como “cloud preferida”, enquanto 2024 e 2025/26 a registram como “cloud no dia a dia”. A equivalência foi verificada de forma explícita: somando as marcações dos três provedores (AWS, Azure e GCP) sobre os respondentes válidos do bloco, a densidade de resposta é praticamente idêntica — 104,5% em 2023 e 104,3% em 2024 —, o que indica que a mudança de rótulo não alterou a natureza da questão, mas a edição de 2023 apresenta uma inversão pontual entre Azure e AWS que destoia do restante da série; recomenda-se, portanto, ler a tendência do período e não o ponto isolado de 2023. Por essa razão, este relatório adota a AWS como o único indicador de

referência da série de cloud, e não a comparação simultânea dos três provedores. A escolha tem três motivos, e nenhum deles é a conveniência de citar o provedor que hospeda o projeto. Primeiro, a decisão que o cliente precisa tomar — em que stack investir e quais certificações financiar — é unívoca: exige eleger um provedor de referência, não descrever um mercado repartido. Segundo, a divergência de rótulo de 2023 afeta os três provedores ao mesmo tempo, de modo que acompanhar três séries multiplicaria por três a incerteza daquele ponto sem alterar a conclusão. Terceiro, a AWS é a única cuja liderança se apoia na edição mais recente e não contaminada (2025/26, 48,3%), com a maior amplitude de crescimento da série (23,3% em 2019 para 48,3% em 2025/26). Azure e GCP permanecem na Figura 10 como contexto de mercado, mas nenhuma recomendação da Seção 12 se apoia neles.



Fonte: State of Data Brasil — Data Hackers/Bain | Edições 2019 a 2025/26 | n = 15.899 · o rótulo da questão diverge em 2023 (ver Seção 8.2); ler a tendência, não o ponto isolado

Figura 10 – Adoção de provedores de cloud — série 2019 a 2025/26 (multirresposta).

8.3 Ferramentas de BI

O Power BI domina o consumo analítico com 59,0% (Figura 11), seguido a distância por Looker Studio e Tableau — padronizar a camada de BI corporativa no líder de mercado facilita contratação e reduz treinamento.




Figura 11 – Ferramentas de BI utilizadas no dia a dia — 2025/26.

9. Inteligência Artificial: Adoção e Impacto (Pergunta 5)

9.1 IA generativa como prioridade corporativa

Na visão dos gestores (Figura 12 e Tabela 13), IA generativa como prioridade máxima ou entre as principais saltou de **36,2% (2023) para 60,6% (2025/26)** — +24,4 p.p. em apenas dois anos, crescimento de 1,7× — enquanto “não é prioridade” despencou de 28,8% para 11,3%. A janela de diferenciação está se fechando: em breve ter IA não distinguirá ninguém — distinguirá quem captura valor primeiro.




Figura 12 – IA generativa como prioridade da empresa — visão dos gestores, 2023 a 2025/26.


Tabela 14 – Prioridade de IA generativa (% dos gestores respondentes).

Categoria	2023	2024	2025/26
Principal prioridade da empresa	12,3%	22,5%	23,8%
Entre as principais (2-4 anos)	23,9%	31,1%	36,8%
Iniciativas isoladas, sem foco	30,7%	28,8%	25,9%
Não é prioridade	28,8%	14,8%	11,3%
Não sabe opinar	4,4%	2,8%	2,1%

9.2 Uso individual de GenAI e Copilots

No nível individual (Figura 13 e Tabela 14), quem “não usa GenAI” caiu de 19,7% para **2,1%** (–17,6 p.p.) e a modalidade “empresa paga” explodiu de 6,4% para **42,4%** — +36,0 p.p., um crescimento de 6,6 vezes; Copilots alcançam 29,8%. Houve forte expansão da participação do uso corporativamente licenciado, embora as modalidades possam coexistir para o mesmo respondente (pergunta multirresposta) — para um banco regulado, prover ferramenta oficial com governança é simultaneamente ganho de produtividade e mitigação de risco de vazamento de dados.

O corte por senioridade (tabela Gold gold_genai_usage_by_seniority, adicionada para tornar este recorte auditável a partir do pipeline) mostra que o uso pago pela empresa não está distribuído igualmente pela pirâmide: sobe de 30,3% no Júnior para 40,8% no Pleno, 45,6% no Sênior e **53,3%** no Especialista/Staff+ — um gap de 23 pontos percentuais entre as pontas (edição 2025/26). A adoção corporativa de GenAI ainda segue a mesma hierarquia de acesso que separa os demais recortes deste relatório: quem já está mais avançado na carreira também captura mais cedo o benefício da ferramenta paga pela empresa.



Fonte: State of Data Brasil — Data Hackers/Bain | Edições 2023, 2024, 2025/26 | n = 3.772 (2023) / 3.619 (2024) / 2.106 (2025/26) · múltipla resposta · 'empresa paga': 6,4% → 42,4%

Figura 13 – Uso individual de IA generativa no trabalho — 2023 a 2025/26 (multirresposta).

Tabela 15 – Uso individual de GenAI (% sobre respondentes válidos).


Modalidade	2023	2024	2025/26
Não usa GenAI	19,7%	6,5%	2,1%
Usa soluções gratuitas	63,7%	53,7%	30,5%
Paga do próprio bolso	6,9%	15,5%	26,9%
Empresa paga	6,4%	19,3%	42,4%
Usa Copilot	11,8%	23,7%	29,8%

10. Regiões e Modelos de Trabalho (Pergunta 6)

10.1 Geografia do talento

O Sudeste concentra 64,4% dos profissionais. A mediana salarial é idêntica em todas as regiões (R\$ 10.001), mas essa igualdade decorre da baixa resolução da faixa (Seção 2.6). A média dos pontos médios revela diferença relevante: R\$ 13.541 no Sudeste contra R\$ 10.330 no Nordeste — 31,1% de amplitude, o que sugeriria arbitragem geográfica. Essa leitura, no entanto, não resiste ao controle de senioridade. Restringindo a comparação ao nível Sênior, as médias regionais praticamente convergem: R\$ 14.867 no Centro-oeste (n=60), R\$ 14.041 no Nordeste (n=86), R\$ 13.847 no Sul (n=140) e R\$ 13.823 no Sudeste (n=526) — amplitude de apenas 7,6%, com o Sudeste na última posição; a região Norte não é exibida neste recorte por não atingir 30 respondentes. A diferença bruta entre regiões é, portanto, efeito de composição: o Sudeste concentra os perfis mais sêniores, não os salários mais altos para uma mesma senioridade. A conclusão para o cliente é precisa: contratar fora do eixo não reduz a banda salarial para o mesmo nível, mas amplia substancialmente o funil de talentos e reduz a concorrência local por perfis experientes. Estes números estão materializados na tabela Gold gold_regions_by_seniority, adicionada à camada Gold para tornar este recorte auditável e reproduzível a partir do pipeline.

Profissionais de dados por região | 2025/26




Fonte: State of Data Brasil — Data Hackers/Bain | Edição 2025/26 | n = 3.370 · a diferença bruta reflete composição de senioridade; no nível Sênior a amplitude cai a 7,6% (Seção 10.1)

Figura 14 – Distribuição regional e salário médio estimado por região — 2025/26.

10.2 O gap entre modelo praticado e desejado

Apenas **1,9% desejam trabalhar 100% presencial**, enquanto 42,1% preferem 100% remoto e 43,0% o híbrido flexível (Figura 15). Política de presença rígida é, na prática, um imposto sobre atração e retenção de talento de dados.



Fonte: State of Data Brasil — Data Hackers/Bain | Edição 2025/26 | n = 3.228 · apenas 1,9% desejam regime 100% presencial

Figura 15 – Modelo de trabalho praticado versus desejado — 2025/26.

10.3 Termômetro do mercado

Em 2025/26, 69,0% declaram-se satisfeitos com a empresa atual e 24,9% relatam layoff na empresa no ano (Tabela 15) — mercado líquido, com talento disposto a ouvir propostas: bom para quem contrata com proposta de valor forte, arriscado para quem não cuida de retenção.


Tabela 16 – Termômetro do mercado por edição.

Edição	Satisfeitos com a empresa	Empresa passou por layoff
2023	72,0%	32,2%
2024	68,6%	28,6%
2025/26	69,0%	24,9%

11. Oportunidades e Desafios (Pergunta 7)

11.1 O que decide a escolha de um empregador

A Figura 16 ordena os critérios de escolha de emprego em 2025/26: remuneração lidera, mas flexibilidade remota, ambiente e oportunidades de crescimento formam o pelotão decisivo — um EVP competitivo para dados combina banda salarial correta com flexibilidade e trilha de carreira visível.



Fonte: State of Data Brasil — Data Hackers/Bain | Edição 2025/26 | n = 3.228 · destaque: os dois critérios mais citados

Figura 16 – CrITÉRIOS decisivos na escolha de onde trabalhar — 2025/26 (multirresposta).

11.2 As dores de quem já gere times de dados

Os desafios relatados pelos próprios gestores do mercado (Tabela 16) antecipam as dores da expansão do cliente: lideram dividir o tempo entre entregas técnicas e gestão (36,3%), gerenciar a expectativa das áreas de negócio (33,3%) e conduzir projetos multidisciplinares (29,1%). Gerar valor para o negócio (23,5%) e garantir qualidade e confiabilidade dos dados (21,6%) vêm logo em seguida — todos à frente de contratar talentos.

Tabela 17 – Principais desafios dos gestores de dados — 2025/26.

Desafio	% dos gestores
Tempo técnico × gestão	36,3%
Expectativa das áreas	33,3%
Projetos multidisciplinares	29,1%
Gerar valor p/ negócio	23,5%
Qualidade dos dados	21,6%
Manutenção em produção	20,4%
Levar inovação	18,7%
Garantir ROI	13,5%

11.3 Síntese: oportunidades × desafios

Tabela 18 – Matriz-síntese de oportunidades e desafios para a instituição financeira.

Dimensão	Oportunidade (evidência)	Desafio (evidência)
Talento	Mercado líquido e remoto amplia o funil (Seção 10)	Competição dura por sêniores; gap na progressão feminina (Seções 5 e 7)
Tecnologia	Stack AWS + Python/SQL alinhada ao mercado (Seção 8)	Qualidade e confiabilidade de dados desafia 21,6% dos gestores (Seção 11.2)
IA	Momento de capturar valor antes da paridade (Seção 9)	Governança do uso e prontidão dos dados internos (Seção 9.2)
EVP	Flexibilidade custa pouco e atrai muito (Figura 16)	Política presencial rígida reduz a atração de talentos (Seção 10.2)

12. Recomendações Estratégicas

12.1 Contratação

- **Bandas salariais por família de cargo e senioridade** ancoradas nas medianas da Seção 6 (Sênior ≈ R\$ 14.001; Especialista ≈ R\$ 18.001), com revisão anual contra a pesquisa.
- **Contratação remota nacional** para senioridades críticas, ampliando o funil de talentos fora do Sudeste, que concentra 64,4% dos profissionais (Seção 10.1).
- **Metas de diversidade na progressão** (promoção a Sênior+), onde o gap é real (-28,6%), somadas à ampliação do acesso feminino à trilha de engenharia de dados (Seção 7.4) — e não apenas na entrada.

12.2 Capacitação

- **Trilha-base obrigatória Python + SQL** (adoção de 92,0% e 84,2% no mercado) e trilha AWS para engenharia.
- **Programa de formação de base (Júnior → Pleno)** para reduzir dependência do mercado de sêniores (Seção 5.3).
- **Letramento em GenAI com governança:** definição de política de uso, disponibilização de ferramenta oficial licenciada e mapeamento de casos de uso priorizados (Seção 9.2).

12.3 Investimento

- **Plataforma de dados em nuvem no padrão Medallion** (a própria arquitetura deste projeto é o blueprint mínimo), com catálogo e qualidade de dados desde o dia 1 — desafio citado por 21,6% dos gestores do mercado (Tabela 16).
- **Licenciamento corporativo de GenAI/Copilots** acompanhando o movimento do mercado (empresa paga: 6,4% → 42,4%), com trilha de auditoria.
- **EVP com flexibilidade** — modelo híbrido flexível/remoto como política declarada (apenas 1,9% desejam presencial integral).
- **Ordem de grandeza de custo (FinOps)** — nos volumes atuais (57 MB no datalake completo) a infraestrutura custa centavos por mês: armazenamento S3 (~US\$ 0,023/GB-mês) é irrelevante nesta escala; cada execução dos dois Glue Jobs (2 workers G.1X, ~US\$ 0,44/DPU-hora) custa poucos centavos; Athena (US\$ 5,00/TB escaneado) cobra frações de centavo por consulta graças ao particionamento por ano=YYYY. Em produção sobre dados reais do banco, o custo escalaria com a frequência de execução e o volume por Job, não com o tamanho do dataset desta pesquisa — o dimensionamento completo fica para a Fase 2.

12.4 Priorização e Quick Wins

A Tabela 18 ordena as recomendações por prioridade e horizonte, com a evidência-âncora de cada uma:

Tabela 19 – Priorização das recomendações.

Ação	Prioridade	Horizonte	Evidência-âncora
Política de uso + licenciamento corporativo de GenAI	Alta	0–90 dias	42,4% já têm GenAI paga pela empresa (9.2)
Trilha obrigatória Python + SQL	Alta	0–90 dias	92,0% / 84,2% de adoção (8.1)
Bandas salariais por família de cargo	Alta	0–90 dias	Medianas das Seções 6.1/6.2
Plataforma Medallion com catálogo e qualidade	Alta	3–12 meses	Qualidade dos dados: 21,6% dos gestores (11.2)
Metas de diversidade na promoção a Sênior+	Alta	3–12 meses	Gap de –28,6% concentrado no Sênior (7.2)
Contratação remota nacional	Média	6–18 meses	Sudeste concentra 64,4%; ampliar o funil (10.1)
Programa de formação de base (Jr → Pleno)	Média	6–18 meses	Escassez relativa de sêniiores (5.3)
EVP com flexibilidade formalizada	Média	6–18 meses	1,9% desejam presencial integral (10.2)

Quick wins — primeiros 90 dias: publicar a política de uso de GenAI, disponibilizar a ferramenta oficial licenciada, lançar a trilha Python + SQL e revisar as bandas salariais contra as medianas desta pesquisa.

Próximos passos de engenharia — produzir o pipeline. Os quick wins acima são de negócio; a arquitetura em si (Seção 3) precisa de quatro peças antes de sustentar decisão em produção: orquestração agendada dos dois Glue Jobs (EventBridge + Step Functions — hoje disparo manual pelo console); alerta de falha (CloudWatch + SNS — hoje sem monitoramento); carga incremental (hoje cada execução sobrescreve a camada inteira, adequado aos 6 CSVs fixos da pesquisa, não a um fluxo contínuo); e um mínimo de CI para os scripts PySpark antes de promover qualquer mudança para produção.

13. Riscos, Limitações e Governança

13.1 Matriz de riscos do projeto

Tabela 20 – Riscos, impacto e mitigação.

Risco	Impacto	Mitigação aplicada
Quebra de schema entre edições	Comparações espúrias	De-para versionado + asserções de colunas no Job 1
Mudança de categorias do questionário	Séries artificialmente quebradas	Harmonização documentada; quebras declaradas (ex.: Especialista/Staff+)
Queda de volumetria em 2025/26	Leitura errada de encolhimento	Uso exclusivo de proporções; n declarado em todo gráfico
Denominador incorreto (multirresposta)	Percentuais distorcidos	Base = respondentes válidos da questão (premissa P6)
Viés de amostragem por conveniência	Generalização indevida	Limitação declarada (Seção 13.2); leitura como 'entre respondentes'
Expiração da sessão do Academy Lab	Retrabalho	Jobs idempotentes (overwrite); dados persistem no S3
Erro no ponto médio salarial	Distorção de medianas	Regra única auditável + correção de typo documentada (P4)

13.2 Limitações metodológicas

A amostra é por conveniência (comunidade Data Hackers), sem pesos amostrais — os resultados descrevem os respondentes da pesquisa, não o universo de profissionais do país. Faixas salariais são ordinais; o ponto médio é estimativa declarada, não salário observado. A categoria Especialista/Staff+ impede comparação direta do topo da pirâmide com edições anteriores.

Somam-se às limitações anteriores: o viés de autorresposta inerente a pesquisas voluntárias; as mudanças de questionário entre edições, que afetam a comparabilidade além das categorias novas já declaradas; a natureza correlacional dos dados, que não autoriza inferência causal; e a ausência de pesos amostrais, que impede projeção estatística para o universo de profissionais do país.

O viés de seleção tem mecanismo conhecido: a pesquisa é divulgada em uma comunidade online de dados, o que superrepresenta profissionais digitalmente engajados e adotantes precoces de tecnologia, e sub-representa setores tradicionais fora desse circuito. A direção provável do viés, portanto, é a **superestimação dos níveis absolutos de adoção** de tecnologias e de IA. Por isso, as tendências direcionais entre edições são mais confiáveis que os níveis absolutos — e todas as conclusões deste relatório devem ser lidas como retrato 'entre respondentes', não como censo do mercado.

Escala validada versus escala de produção. O pipeline foi validado em 22.686 linhas processadas em lote anual — volume trivial para qualquer engine moderna. A arquitetura aqui construída é o blueprint mínimo (Seção 3.1), não uma validação de escala: dados reais de RH/operações de uma instituição financeira de grande porte têm ordens de grandeza a mais e cadência mais frequente que uma pesquisa anual. Levar esta arquitetura a produção exigiria revisar o número de workers do Glue (hoje fixo em 2×G.1X, sem auto scaling), remover o coalesce(1) na gravação do CSV Gold (adequado a agregados pequenos, não a cargas maiores) e avaliar processamento por streaming caso a cadência deixe de ser em lote.

Escopo da governança de dados. A Seção 2 rastreia premissas metodológicas e a Tabela 19 mapeia riscos do projeto analítico entregue — governança de dado em produção (papéis e responsabilidades, política de qualidade contínua, monitoramento) não faz parte deste escopo.

Riscos operacionais da plataforma recomendada — falha de job sem alerta, dependência de fornecedor, ownership da camada Silver em produção — ficam para a fase de implementação.

13.3 Reprodutibilidade

Todo o fluxo é reproduzível do zero: notebooks 01–05 executados com outputs reais, jobs idempotentes, de-para e premissas versionados em config/, e consultas SQL portáteis (Spark 3.x/Athena). Qualquer membro do grupo — ou o avaliador — chega aos mesmos números a partir dos CSVs públicos.

13.4 Validação cruzada das interpretações

Nem toda leitura intuitiva dos dados resistiu à verificação. Seis hipóteses plausíveis foram testadas contra a camada Gold antes de virarem conclusão; **quatro foram refutadas e tiveram o texto reescrito**. O registro desses testes é parte da governança analítica do projeto: documenta não apenas o que concluímos, mas o que descartamos e por quê.

Tabela 21 – Hipóteses testadas, resultado da verificação e decisão adotada.

Leitura intuitiva inicial	Teste aplicado	Resultado	Decisão adotada
Ciência de Dados é menos valorizada que Engenharia de Dados	Controle por senioridade (Seção 6.3)	Medianas idênticas em todos os níveis; diferença bruta explicada por composição	Conclusão descartada; equivalência declarada
Contratar fora do Sudeste reduz o custo salarial	Mediana salarial por região (Figura 14)	Medianas equivalentes: R\$ 10.001 em todas as regiões	Argumento reescrito para ampliação do funil de talentos
Qualidade de dados é a principal dor dos gestores	Ranking de desafios (Tabela 16)	É a 5ª dor (21,6%); lidera tempo técnico × gestão (36,3%)	Texto corrigido em quatro pontos do relatório
Mulheres ganham menos em toda a carreira de dados	Controle por senioridade (Seção 7.2)	Gap nulo em Júnior e Pleno; -28,6% surge no Sênior	Conclusão redirecionada para promoção, não contratação
Salários regionais mais baixos fora do Sudeste	Média do ponto médio controlada por senioridade	Amplitude cai de 31,1% para 7,6%; Sudeste em último no nível Sênior	Arbitragem geográfica descartada; mantida a ampliação do funil
A série de cloud estaria quebrada por mudança de pergunta	Comparação da natureza das respostas entre edições	Densidade de marcação equivalente: soma de AWS+Azure+GCP sobre a base válida do bloco = 104,5% (2023) e 104,3% (2024)	Hipótese não confirmada; registrada ressalva de rótulo

O padrão comum às refutações é instrutivo: em três dos quatro casos o erro potencial vinha de comparar grupos com composição interna diferente. Por isso o controle por senioridade foi aplicado de forma consistente tanto à análise de cargo quanto à de gênero.

14. Conclusões

As três últimas edições da State of Data Brasil descrevem um mercado que amadureceu tecnicamente (Python/SQL como base universal, AWS na liderança de cloud), encareceu no topo da senioridade e entrou em aceleração declarada de IA generativa — com a adoção corporativa paga saltando de **6,4% para 42,4%** em dois anos. Ao mesmo tempo, expõe fragilidades estruturais: estagnação da participação feminina, gap de progressão no nível Sênior e um descompasso severo entre o modelo de trabalho praticado e o desejado.

Para a instituição financeira, a leitura estratégica é uma só: **a vantagem competitiva não estará em adotar IA — estará em ter dados confiáveis, plataforma moderna e gente capaz de capturar valor antes da paridade do mercado**. As recomendações da Seção 12 traduzem essa leitura em ações de contratação, capacitação e investimento, cada uma rastreável a um número deste relatório — e o pipeline AWS aqui construído é, ele próprio, o protótipo funcional da plataforma recomendada.

Por fim, declara-se respondida a pergunta norteadora: as três últimas edições da pesquisa mostram, com evidência quantitativa, **quem contratar** (famílias e senioridades da Seção 6, com bandas realistas), **o que capacitar** (Python, SQL, AWS e letramento em GenAI governada) e **onde investir** (plataforma de dados moderna com qualidade e catálogo, e IA generativa corporativa antes da paridade de mercado). A arquitetura construída neste projeto não apenas produziu essas respostas — é, ela própria, o protótipo funcional da plataforma que sustentará as decisões estratégicas da instituição financeira.

15. Referências

- DATA HACKERS; BAIN & COMPANY. State of Data Brazil: edições 2019, 2021, 2022, 2023, 2024 e 2025/26. Kaggle, 2026. Disponível em: <https://www.kaggle.com/datahackers/datasets>. Acesso em: 17 jul. 2026.
- BAIN & COMPANY. Pesquisa de adoção de IA generativa no Brasil. 2025. Disponível em: <https://www.bain.com/pt-br/insights/inteligencia-artificial-no-brasil/>. Acesso em: 26 ago. 2026.
- MCKINSEY & COMPANY. The State of AI. 2025. Disponível em: <https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>. Acesso em: 26 ago. 2026.
- DATABRICKS. Medallion Lakehouse Architecture: documentação oficial. Disponível em: <https://docs.databricks.com/aws/en/lakehouse/medallion>. Acesso em: 17 jul. 2026.
- AWS BUILDERS (comunidade dev.to, publicação não oficial). Medallion Architecture on AWS (S3 + Glue + Athena). Disponível em: <https://dev.to/aws-builders/medallion-architecture-on-aws-2ngm>. Acesso em: 26 ago. 2026.
- BRASSCOM. Censo de Diversidade do Setor de TIC 2024–2025. Disponível em: <https://brasscom.org.br/relatorio-diversidade-setor-de-tic-em-2024/>. Acesso em: 26 ago. 2026.

Nota de curadoria: fontes externas foram usadas apenas como contexto/benchmark; todos os números do relatório saem do pipeline sobre os CSVs oficiais da pesquisa.